

基于 I-GWO-BP 神经网络的柴油机 NO_x 排放预测模型

张凯强¹,王勇^{2,3},翟军强^{2,3},江先锋¹,王小雷¹,王宁峰⁴

(1.青海大学机械工程学院,青海 西宁 810016;2.青海省高原科技发展有限公司,青海 西宁 810006;
3.青海省内燃动力机械高原动力和排放重点实验室,青海 西宁 810006;4.青海大学化工学院,青海 西宁 810016)

摘要:针对高原环境不同海拔地区工程机械柴油发动机 NO_x 排放与实际运行工况之间的复杂非线性关系,提出了一种基于维度学习的狩猎(DLH)搜索策略改进 GWO-BP 神经网络的 NO_x 排放预测模型。利用便携式排放测试系统(PEMS)对高原地区叉车进行不同海拔下的实际运行工况排放试验,并将试验数据作为数据集,通过随机森林算法完成预测模型的输入特征选择。结果表明:I-GWO-BP 模型相对于 BP 和 GWO-BP 模型在评价指标 RMSE 和 R² 上表现更优, RMSE 和 R² 分别为 4.623 3 mg/s 和 0.925 1,该模型对高原地区不同海拔下工程机械 NO_x 排放的预测精度更高。

关键词:高原;氮氧化物;特征参数;预测模型

DOI: 10.3969/j.issn.1001-2222.2024.06.012

中图分类号:TK421.5 **文献标志码:**B **文章编号:**1001-2222(2024)06-0083-07

我国地形地势变化复杂,海拔 1 000 m 以上的土地面积占全国总面积的 58%,2 000 m 以上的土地面积占 33%^[1]。在高海拔地区,低气压和低氧气浓度对发动机燃油消耗和污染物排放有显著影响^[2-6]。排放污染物对人体健康和空气环境都会造成严重的危害,是光化学烟雾和灰霾的重要成因,根据我国“2030 年碳达峰、2060 年碳中和”的目标及需求,高原地区工程机械排放总量的控制及预测具有重要的意义。

叉车是一种重要的非道路物料搬运设备,在世界范围内得到了广泛的应用。与其他非道路移动机械总量相比,叉车的数量相对较多^[7],占全国的移动机械总量的 18.3%。同时,根据《中国移动源环境管理年度报告(2023)》,叉车是污染物排放量前三的工程机械之一^[8]。为了更好地控制非道路移动源排放,有必要研究非道路移动源的污染物排放预测模型。部分排放研究是在试验室台架试验的基础上进行的,而已经有研究证明台架试验与实际排放存在差异^[9]。因此,柴油发动机在实际运行工况中的数据收集是一个重要的基础,它在排放预测的研究中具有重要意义。

在不同海拔的非道路移动源实际排放测量的研究中,一般使用基于 NDIR 和 NDUV 原理的传感器对排放污染物进行测量,但传感器测量方法仍存在标定、结构复杂等诸多应用问题。同时试验的周期长、费用高、可重复性低^[10],海拔落差巨大,这给高原地区的工程机械排放测量带来了较大的困难。因此,需要研究柴油发动机在高原地区不同海拔下的排放预测模型。作为机器学习方法的代表,神经网络通过激活函数,可以以任意精度逼近任意非线性函数^[11],特别适合求解内部机制复杂的问题。虽然人工神经网络(ANN)在作为解决广泛问题的工具方面发挥了重要的作用,但也存在一些缺点,例如陷入局部最优和收敛速度慢。因此,研究者开发了许多智能优化算法,如遗传算法、粒子群算法等,对 ANN 的初始权值和阈值进行初步优化,使用优化后的权值和阈值对神经网络进行训练,可以加快网络的收敛速度,获得全局最优值。X. CHEN 等^[12]使用鹈鹕优化算法(POA)优化 BP 神经网络的权重和阈值,建立了瞬态 NO_x 预测模型。钱枫等^[13]使用动态改进遗传粒子群算法对 BP 神经网络进行动态改进,建立了重型车辆 NO_x 排放预测模型。闻

收稿日期:2024-03-08;修回日期:2024-05-28

基金项目:青海省科学技术厅项目(2019-GX-A6);青海省基础研究计划项目(2023-ZJ-780)

作者简介:张凯强(1996—),男,硕士,主要研究方向为湿生物质干燥控制;763248951@qq.com。

通讯作者:王宁峰(1976—),男,教授,主要研究方向为过程装备与控制;wnfeng@163.com。

增佳等^[14]引入遗传蚁群混合算法对 BP 神经网络进行优化,重型车的排放预测准确性较好。H. YU 等^[15]基于 GA-BP 算法建立了国六汽车的 NO_x 和 PN 预测模型。灰狼算法(GWO)是一种元启发式算法,原理类似于狼群追逐猎物的过程^[16],与其他优化算法相比,灰狼算法参数较少,结构简单,全局搜索能力较强^[17]。

本研究以工程机械叉车为例,利用便携式排放测量系统(PEMS)在中国 3 个不同海拔地区进行实际运行工况试验,结合车载诊断系统(OBD)读取的叉车工况数据,使用 I-GWO 优化 BP 神经网络模型,建立预测不同海拔下 NO_x 排放量的模型。使用基于维度学习的狩猎搜索策略改进的灰狼算法优化 BP 神经网络,将该算法应用于柴油发动机的排放预测。预测模型可以作为估算高原区域燃油消耗和污染物排放的工具,为区域碳排放、污染排放控制提供数据支持及评估方法。

1 试验设备及方法

1.1 试验设备

本研究中工程机械的整备质量为 4 820 kg,表 1 列出了工程机械发动机的规格参数。试验设备采用 Sensors 的 SEMTECH 车载尾气分析系统,主要包括 SEMTECH SCS 供电通讯系统、SEMTECH GAS 基础气体分析系统、SEMTECH CPN 颗粒物数量测量系统和 SEMTECH EFM5 尾气流量计共 4 个功能模块。测试设备及布置示意图 1 所示。

表 1 工程机械发动机规格参数

参数	数值
型号	V32-50C42
排量/L	3.17
燃料喷射系统	高压共轨
缸数	4
缸径/mm	98
行程/mm	105
标定净功率/kW	36.8
标定转速/($\text{r} \cdot \text{min}^{-1}$)	2 500
最大扭矩/($\text{N} \cdot \text{m}$)	200
排放标准	国 IV



图 1 测试设备示意

1.2 试验方法

针对同一台工程机械分别在中国的兰州(平均海拔 1 500 m)、西宁(平均海拔 2 400 m)和海晏(平均海拔 3 095 m)3 个不同海拔地区进行实际运行工况研究试验,由于工程机械在实际作业过程中工况变化十分复杂,为了获得具有代表性的尾气排放特征,根据工程机械的工作特点,按照设定工况(冷机怠速、空载行走、原地举升、重载行走、复合作业、热机怠速)对不同典型工况下的排放污染物进行测试。在此测试过程中,1 s 收集并记录 9 个相关参数。在这些参数中,选择 NO_x 排放作为预测模型的输出参数。使用 SEMTECH 车载尾气分析系统测量环境温度、环境湿度、海拔、车速以及 NO_x 排放量, OBD 实时收集扭矩百分比、发动机转速、冷却液温度和机油压力。

2 数据处理

2.1 基于随机森林算法的输入变量选择

在实际运行工况测试中测量了许多参数,但并非所有参数都与排放有关,使用无关数据进行神经网络训练是无效的,只会降低神经网络模型的实用性。因此,有必要进行输入变量的选择,减少模型输入的数量,避免使用影响预测精度的冗余参数,从而降低计算成本,增加模型的可解释性。随机森林(random forest, RF)是 Breiman 在 2001 年提出的一种监督机器学习算法^[18],由可以执行分类计算的决策树组成。图 2 示出了随机森林的基本结构,其是由具有分类函数的决策树组成的集成学习算法。随机森林不仅可以用于分类^[19]和回归预测^[20],同时也可以用于特征选择^[21],可以判断不同变量之间的相互影响及其对模型的重要性,这有助于在建立模型时优化输入变量^[22]。

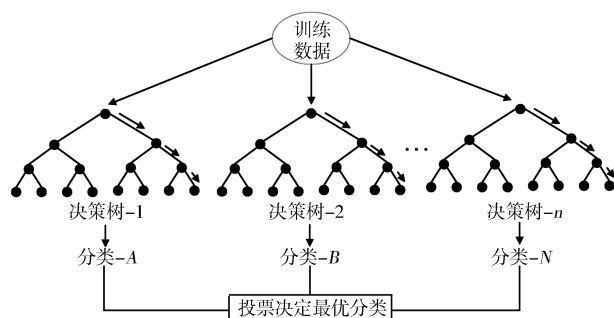


图2 随机森林模型

2.2 数据归一化

在划分数据集时,通常采用手动划分和随机划分的方法。为了避免手工划分的主观性,通常采用随机划分的方式来减少偏差。6种工况的数据总量为7200组,随机选取80%数据分配给训练集,剩余20%数据分配给测试集。试验数据具有不同的量纲,为了不影响数据分析的结果并消除量纲的影响,采用式(1)对数据进行归一化并将值映射到 $[0,1]$ 的范围。

$$y = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \quad (1)$$

式中: y 为归一化后的值; x_{\max} 为待处理样本数据的最大值; x_{\min} 为待处理样本数据的最小值; x_i 为待处理的样本数据;

3 I-GWO 优化 BP 神经网络

3.1 BP 神经网络

误差反向传播神经网络(BPNN)是一种多层映射网络,它在向前传输信息的同时使向后的误差最小化。作为一种经典的神经网络模型,BPNN是由输入层、隐藏层和输出层组成的多层型神经网络,隐藏层可扩展为多层,结构如图3所示,图中 X_i 为输入层, Y_i 为输出层, ω_{ij} 和 ω_{jk} 为BP网络权重。




图3 BP神经网络结构

当训练数据从外部导入到网络中,首先被输入到输入层,然后经隐藏层逐层向后传播,直到输出

层。通过对输入变量、权值、偏差和传递函数的线性或非线性组合,信息存储到网络中并沿着减少误差的方向传递,最后得到预测结果。

BP神经网络的优点是其灵活的非线性建模能力,强适应性,以及大规模并行计算的能力,具有广泛的应用前景。使用BP神经网络建立工程机械在不同海拔的排放预测模型。隐藏层神经元数的范围通过经验公式确定:

$$H = \sqrt{m + n} + a \quad (2)$$

式中: H 为隐藏层的神经元个数; m 为输出层的神经元个数; n 为输入层的神经元个数; a 为 $[0,10]$ 之间的常数。

用于输入层和隐藏层之间连接的激活函数是S型函数(tansig函数)。隐藏层和输出层之间的激活函数是线性函数(purelin函数)。BP神经网络最终的训练结果在很大程度上依赖于初始的权值和阈值,由于初始参数的随机生成机制,无论层数和神经元数如何,BP神经网络都容易陷入局部最优,导致网络不能准确预测,若求解目标复杂,还会导致算法收敛缓慢。为了解决这个问题,采用改进的灰狼算法对BP神经网络模型的初始权重和偏置进行优化,以进一步提高预测精度。

3.2 改进的灰狼算法

灰狼算法(GWO)是一种结构简单、参数少的新元启发式算法,它模仿了自然界灰狼的等级制度和狩猎机制。采用 α, β, δ 和 ω 4种类型的灰狼来模拟社会等级制度。此外,还实现了狩猎、搜索猎物、包围猎物、攻击猎物4个主要步骤^[16]。

在GWO中, α, β 和 δ 引导 ω 狼群在搜索空间中找到最优解的区域。这种行为可能会导致GWO陷入局部最优,还会降低种群的多样性。为了克服这些问题,引入基于维度学习的狩猎搜索策略对灰狼算法进行改进^[23](I-GWO)。I-GWO包括3个阶段:初始化、运动和更新。

1) 初始化阶段

N 只狼按照式(3)在 $[l_j, u_j]$ 范围内随机分布在搜索空间中。

$$X_{ij} = l_j + \text{rand}_j [0, 1] \times (u_j - l_j), \\ i \in [1, N], j \in [1, D] \quad (3)$$

式中: D 为问题的维度; u_j 和 l_j 为上下边界。

2) 运动阶段

I-GWO中引入了一种运动策略,称为基于维度学习的狩猎搜索策略(DLH)。在DLH搜索策略中,每只灰狼通过多邻域学习,构建候选狼 X_{DLH} 。

首先,通过式(4)计算当前灰狼位置 $X_i(t)$ 与 $X_{i-GWO}(t+1)$ 之间的欧几里得距离 $R_i(t)$:

$$R_i(t) = \|X_i(t) - X_{i-GWO}(t+1)\|。 \quad (4)$$

以 $R_i(t)$ 为半径,构造邻域 $N_i(t)$,如式(5)所示:

$$N_i(t) = \{X_j(t) \mid D_i(X_i(t), X_j(t)) \leq R_i(t), X_j(t) \in \text{Pop}\}。 \quad (5)$$

式中: D_i 为 $X_i(t)$ 和 $X_j(t)$ 之间的欧氏距离。

通过式(6)进行多邻域学习:

$$X_{i-DLH,d}(t+1) = X_{i,d}(t) + \text{rand} \times (X_{n,d}(t) - X_{r,d}(t))。 \quad (6)$$

式中: $X_{i-DLH,d}(t+1)$ 为 DLH 策略的第二候选位置。

3) 选择和更新阶段

通过比较 $X_{i-GWO}(t+1)$ 和 $X_{i-DLH}(t+1)$ 两个候选的适应度值来选择更优的个体,计算公式如下:

$$X_i(t+1) = \begin{cases} X_{i-GWO}(t+1), & \text{if } f(X_{i-GWO}) < f(X_{i-DLH}) \\ X_{i-DLH}(t+1), & \text{otherwise} \end{cases}。 \quad (7)$$

3.3 I-GWO 优化 BP 神经网络

GWO-BP 算法是利用改进的灰狼算法对 BP 神经网络的初始权值和阈值进行优化,并将优化结果用于训练 BP 模型。I-GWO-BP 神经网络模型的流程图如图 4 所示。首先,将经过特征选择的数据进行归一化处理,随机选取训练集和测试集。然后初始化 I-GWO 和 BP 神经网络的结构参数,计算每个灰狼的个体适应度,利用 DLH 搜索策略进行灰狼的位置更新,判断是否满足终止条件,如满足则为初始权值和阈值的最优解。最后,将 BP 神经网络使用 I-GWO 优化后的初始权值和阈值进行训练,完成 NO_x 排放的预测。

定义灰狼算法中的参数 N 和 D ,其中, N 表示灰狼种群的种群数量, D 表示灰狼个体的搜索空间维度。每只灰狼的位置代表 BP 神经网络的所有初始权值和阈值,在迭代过程中找到最优的 α 狼位置,即为神经网络最优的初始权值和阈值。搜索空间维度的计算公式如下:

$$D = a \times b + b + b \times c + c。 \quad (8)$$

式中: D 为灰狼个体的搜索空间维数; a 为输入层的神经元数; b 为隐藏层的神经元数; c 为输出层的神经元数。

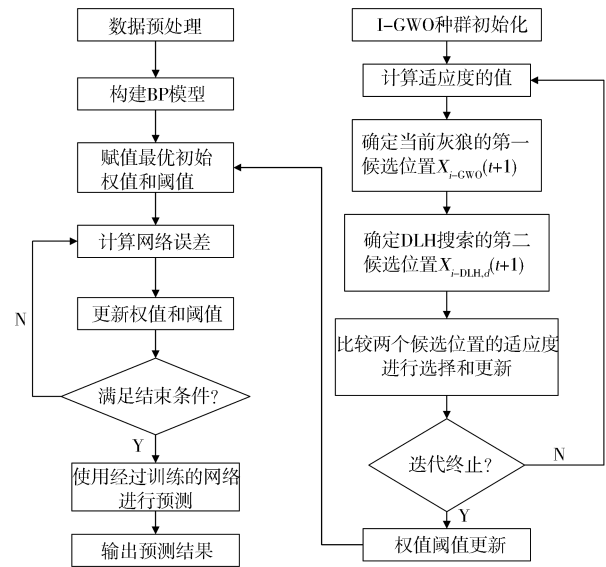


图4 I-GWO-BP神经网络模型流程图

适应度函数定义为 BP 神经网络预测输出和期望输出之间的均方根误差,计算公式如下:

$$F = \sqrt{\frac{\sum_{i=1}^N (\exp_i - \text{pre}_i)^2}{N}}。 \quad (9)$$

式中: N 为用于训练的数据数量; \exp_i 为试验过程中某一时刻排放的实测值; pre_i 为试验过程中某一时刻排放的预测值;

3.4 评价指标

利用 Origin 软件绘图,采用 Matlab 软件进行程序的编写和数据处理。使用决定系数 R^2 和均方根误差 (root mean square error, RMSE) 作为预测模型的拟合评价指标。 R^2 越接近于 1, RMSE 和相对误差越接近于 0, 则说明此预测模型拟合的效果越好。评价指标的计算公式如下:

$$R^2 = 1 - \frac{\sum_{i=1}^N (\exp_i - \text{pre}_i)^2}{\sum_{i=1}^N (\exp_i - \text{aver})^2}, \quad (10)$$

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\exp_i - \text{pre}_i)^2}。 \quad (11)$$

式中: \exp_i 为排放试验过程中某一时刻 NO_x 的实测值; pre_i 为排放试验过程中某一时刻 NO_x 的预测值; aver 为排放试验过程中样本 NO_x 的均值; N 为试验测试点总数。

4 预测模型结果分析

4.1 特征重要性分析

每组试验数据记录了 9 个参数,其中包括需要预测的参数 NO_x 排放,而环境温度、环境湿度、海拔、车速、扭矩百分比、发动机转速、冷却液温度和机油压力作为待定的输入参数,这些参数为初步筛选的参数,其中的一些参数可能对实际排放的影响并不强,直接使用初步筛选的参数作为输入可能会影响预测精度。由图 5 可以看出,输入变量扭矩百分比对 NO_x 排放的影响最大,而冷却液温度和机油压力对 NO_x 排放的影响较小。因此,选择与输出 NO_x 对应的 6 个最重要的输入变量作为预测模型的输入,分别是环境温度、环境湿度、海拔、车速、扭矩百分比和发动机转速。




图 5 预测模型输入变量的重要性

4.2 预测模型性能分析

BP,GWO-BP,I-GWO-BP 3 种预测模型预测 NO_x 的结果如图 6 所示。从 6 中可以看出,3 种预测模型都有效地预测了不同海拔下的 NO_x 排放值。BP,GWO-BP,I-GWO-BP 的 RMSE 分别为 5.155 2 mg/s,4.877 3 mg/s,4.623 3 mg/s,说明 3 种模型在训练过程中都能较好地获得输入和输出的关系。然而,在较突出的峰值处,BP 神经网络模型的预测结果最差,与实际值具有显著的误差,I-GWO-BP 模型的预测值与其他 2 种预测模型相比更接近实际值,在峰值处的拟合度最高。虽然仍有个体偏差较大,但是数量稀少。




图 6 3 种预测模型测试集的预测结果

图 7 示出了数据集预测值和试验值的回归分析。BP,GWO-BP,I-GWO-BP 预测模型测试集的决定系数 R^2 分别为 0.906 8,0.916 7,0.925 1,说明 I-GWO-BP 预测模型比其他 2 个模型具有更高的非线性拟合能力,能够较好地预测 NO_x 的排放。




图 7 测试集的预测值与试验值的回归分析

同样,这些结果凸显了 I-GWO-BP 预测精度的提高以及模型适应 NO_x 排放的能力,表明 I-GWO-BP 网络可以有效地用于探索柴油机 NO_x 排放变量之间的关系,表现出了强大的学习能力;I-GWO-BP 预测模型的预测精度高于其他 2 个模型,表明通过 I-GWO 优化 BP 神经网络会使预测结果更加准确。

5 结束语

在 BP 神经网络预测模型的基础上,建立了基

于维度学习的狩猎搜索策略改进的 GWO 优化 BP 神经网络的 NO_x 预测模型,采用不同海拔下的实际运行工况数据作为数据集。利用随机森林算法,选择环境温度、环境湿度、海拔、车速、扭矩百分比和发动机转速 6 个最重要的变量作为预测模型的输入,以降低数据维度和计算成本。I-GWO-BP 预测模型可以保持种群的多样性,并且提高了全局和局部搜索能力。使用 R^2 和 RMSE 分析和评估 3 种预测模型在训练和测试数据集中的预测性能,与 BP 神经网络预测模型和 GWO-BP 预测模型相比,I-GWO-BP 模型的 RMSE 和 R^2 都有所改善,说明 I-GWO-BP 模型在不同海拔下对 NO_x 的预测具有更高的预测精度。

参考文献:

- [1] ZHENG Y M, XIE L B, LIU D Y, et al. Emission Characteristics of Heavy-Duty Vehicle Diesel Engines at High Altitudes [J]. Journal of Applied Fluid Mechanics, 2023, 16(12): 2329.
- [2] WANG Yachao, GE Yunshan, WANG Junfang, et al. Impact of altitude on the real driving emission(RDE) results calculated in accordance to moving averaging window(MAW) method[J]. Fuel, 2020, 277: 117929.
- [3] YAN Junhao, GAO Suyu, ZHAO Weihua, et al. Study of combustion and emission characteristics of a diesel engine fueled with diesel, butanol-diesel and hexanol-diesel mixtures under low intake pressure conditions [J]. Energy Conversion and Management, 2021, 243: 114273.
- [4] 雷蕾, 於永华, 申立忠, 等. 不同海拔下柴油机瞬态排放试验[J]. 内燃机学报, 2023, 41(5): 420-426.
- [5] 王建, 于威, 王斌. 高原状态下甲醇替代率对柴油机燃烧与排放的影响[J]. 吉林大学学报(工学版), 2023, 53(4): 954-963.
- [6] 郑丰, 赵海光, 吉江林, 等. 基于北京和昆明海拔条件下的国 VI 混合动力车实际道路排放特性研究[J]. 环境科学研究, 2022, 35(7): 1581-1588.
- [7] PANG Kaili, ZHANG Kaishan, MA Shuai. Tailpipe emission characterizations of diesel-fueled forklifts under real-world operations using a portable emission measurement system[J]. Journal of Environmental Sciences, 2021, 100: 34-42.
- [8] ZHANG Mi, LIU Xiaoyong, LI Kunpeng, et al. Real-world emission for in-use non-road construction machinery in Wuhan, China[J]. Environmental Science and Pollution Research, 2023, 30(16): 46414-46425.
- [9] HOU Xiuning, ZHANG Xuemin, HUANG Shengcao, et al. Measurement of engine performance and maps-based emission prediction of agricultural tractors under actual operating conditions [J]. Measurement, 2023, 222: 113637.
- [10] DU Baocheng, ZHANG Li, ZOU Jie, et al. Investigating the impact of route topography on real driving emission tests based on large data sample at data window level[J]. Science of The Total Environment, 2022, 809: 151133.
- [11] DU Shenglin, GONG Man, WANG Qinpeng. Development of a NO_x Calculation Model for Low-Speed Marine Diesel Engines Based on Soft Measurement Technology [J]. Applied Sciences, 2023, 13(11): 63-73.
- [12] CHEN Xu, BAI Shuzhan, LI Guoxiang, et al. A new transient NO_x prediction model for diesel engine based on neural network model with Pelican Optimization Algorithm [J]. International Journal of Engine Research, 2023, 25(1): 231-239.
- [13] 钱枫, 马骋, 祝能, 等. 基于动态改进遗传粒子群-BP 的重型车 NO_x 排放预测模型研究[J]. 车用发动机, 2023(5): 63-71.
- [14] 闻增佳, 谭建伟, 王怀宇, 等. GA-ACO 算法优化 BP 神经网络的重型车排放预测[J]. 重庆理工大学学报(自然科学), 2022, 36(12): 202-209.
- [15] YU Hao, CHANG Hong, WEN Zengjia, et al. Prediction of Real Driving Emission of Light Vehicles in China VI Based on GA-BP Algorithm[J]. Atmosphere, 2022, 9: 6-7.
- [16] SEYEDALI M, SEYEDMOHAMMAD M, ANDREW L. Grey Wolf Optimizer [J]. Advances in Engineering Software, 2014, 69: 46-61.
- [17] SHI G, ZHAO J, WANG H, et al. Characteristics and GWO-ANN Model Based on Prior Knowledge for Contact Resistance in a Pantograph-Catenary[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-11.
- [18] LEO B. Random Forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [19] MARIANA B, LUCIAN D. Random forest in remote sensing: A review of applications and future directions[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2016, 114: 24-31.
- [20] HAMED K, AMIR R. Predicting the carbon dioxide emission caused by road transport using a Random Forest(RF) model combined by Meta-Heuristic Algorithms [J]. Sustainable Cities and Society, 2023, 93: 104503.
- [21] XIONG Jinlin, PENG Tian, TAO Zihan, et al. A dual-

scale deep learning model based on ELM-BiLSTM and improved reptile search algorithm for wind power prediction[J].Energy,2023,266:126419.

- [22] WANG Changbai,XU Shuzhan,LIU Jimin,et al.Building an improved artificial neural network model based on deeply optimizing the input variables to enhance rutting

prediction[J].Construction and Building Materials,2022,348:128658.

- [23] MOHAMMADH N S,SHOKOOH T,SEYEDALI M R.An improved grey wolf optimizer for solving engineering problems[J].Expert Systems with Applications,2021,166:113917.

NO_x Emission Prediction Model of Diesel Engine Based on I-GWO-BP Neural Network

ZHANG Kaiqiang¹,WANG Yong^{2,3},ZHAI Junqiang^{2,3},
JIANG Xianfeng¹,WANG Xiaolei¹,WANG Ningfeng⁴

(1.School of Mechanical Engineering,Qinghai University,Xining 810016,China;

2.Qinghai Plateau Science and Technology Development Co.,Ltd.,Xining 810006,China;

3.Qinghai Provincial Key Laboratory of Plateau Power and Emission of Internal
Combustion Power Machinery,Xining 810006,China;

4.School of Chemical Engineering,Qinghai University,Xining 810016,China)

Abstract: For addressing the complex nonlinear relationship between NO_x emissions from diesel engines of construction machinery in different altitudinal regions of plateau environments and actual operational conditions, a diminishing learning-based hunting(DLH) search strategy to improve the grey wolf optimizer(GWO)-BP was proposed to optimize a BP neural network model for predicting NO_x emissions. A portable emission measurement system(PEMS) was used to conduct emission tests on forklifts in plateau areas under various altitudinal operational conditions, and the experiment data were served as the dataset. Feature selection for the prediction model input was completed using the random forest algorithm. The results showed that the I-GWO-BP model outperformed both the BP and GWO-BP models in terms of evaluation metrics RMSE and R^2 , with RMSE and R^2 values of 4.623 3 mg/s and 0.925 1 respectively. The model exhibited good prediction accuracy for NO_x emissions from construction machinery at different altitudes in plateau areas.

Key words: plateau;nitrogen oxides;feature parameter;prediction model

[编辑:姜晓博]

(上接第 82 页)

Nonlinear Combined Estimation of Lithium Battery SOC Based on Parameter Identification of Equivalent Circuit Model

GAO Yanzeng^{1,2},WANG Jian³,XU Donghui³

(1.School of Computer Science, Jiaying University, Meizhou 514015, China;

2.School of Civil Engineering and Transportation, South China University of Technology, Guangzhou 510641, China;

3.Nanchang Normal University, Nanchang 330032, China)

Abstract: Because lithium-ion battery is a rigid system, it presents rich nonlinear dynamic characteristics and high complexity. The parameters of the equivalent circuit model and SOC state show time-varying slowly with the use of the battery, and the SOC estimation method of using the gauge usually has some shortcomings such as low accuracy and poor timeliness. The charge control memristor was connected to a first-order RC model as a load to establish a fourth-order chaotic system. The unknown parameters of fourth-order chaotic system were identified online by using a state observer, and the R_0 , R_1 and C_1 values of first-order RC model parameters were obtained in real time. The mathematical expression of the accurate first-order RC model was established by using the online parameter identification values. Then AEKF and SVR models were used to estimate SOC time series in real time, and SOC estimated values of the two models were obtained. Using the LSTM model nonlinear combination of AEKF and SVR model estimated values, the final lithium-ion battery SOC estimated values were finally obtained. The experimental results show that the nonlinear combined estimation model can accurately estimate SOC in real time, which indicates that the proposed nonlinear combined estimation model has better nonlinear dynamic estimation ability, higher accuracy and generalization ability.

Key words: lithium-ion battery;SOC;estimation;equivalent circuit;chaotic system;parameter identification [编辑:袁晓燕]